

A Neurobiological Evaluation Metric for Neural Network Model Search

Proposed a human-model similarity metric.

Networks with increased human-model similarity are correlated with better performance on two computer vision tasks: next frame prediction and object matching accuracy.

Why ReLU networks yield high-confidence predictions far away from the training data and how to mitigate the problem

辨别器网络应该在输入不可信的时候给出较低的预测概率。文章证明了ReLU网络本身达不到这个目标。文章还提出了一个处理这种问题的方法。

CollaGAN: Collaborative GAN for Missing Image Data Imputation

多输入网络当输入数量少于预设情况时输出有很大偏差。文章提出了一种输出减少时图像插补措施 CollaGAN。CollaGAN使用clean dataset来预测丢失数据。

Mode Seeking Generative Adversarial Networks for Diverse Image Synthesis

<https://github.com/HelenMao/MSGAN>

conditional generation tasks期望在给定条件的情况下输出具有多样性，但是cGANs并不在意隐变量 z ，这使得output variations有所增加。对于cGANs的mode collapse问题，作者提出了一个正则项

$\frac{d_I(I_a, I_b)}{d_z(z_a, z_b)}$ 来提高输出网络的多样性。

早期研究成果

GAN

[Goodfellow I. J., Pouget-Abadie J., Generative Adversarial Nets NIPS2014](#)

Input: random noise z

Loss: 对抗loss

Architecture: perceptron

问题:

1. 训练结果不稳定，常生成"诡异"图像
2. 生成目标不明确，可控性不强
3. G、D训练需要均衡。如果D的辨别能力特别强，则G不会学到任何东西。

cGAN

[Mirza M. Conditional Generative Adversarial Nets NIPS2014](#)

Input: condition y + noise z

Loss: 对抗loss

问题:

1. 图像边缘模糊
2. 生成图像分辨率较低
3. 可训练性不强

贡献:

图像风格转换鼻祖(CycleGAN, StarGAN)

DCGAN

[Radford A., Metz L. Unsupervised Representation Learning with Deep Convolution Generative Adversarial Networks](#)

Input: random noise z

Loss: 对抗loss

问题:

生成结果不稳定

贡献:

1. 全卷积网络
2. 每层之后进行batch normalization保证梯度
3. 输入的连续性

WGAN

[Arjovsky M., Chintala S., Bottou L. Wasserstein GAN](#)

贡献:

1. KL(JS)散度不合理, generator梯度弥散
2. Generator Loss: EMD